

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO



Clasificación no supervisada utilizando un modelo bayesiano de mezclas

TESIS

QUE PARA OBTENER EL TÍTULO DE

Licenciada en Actuaría

PRESENTA

Montserrat Vizcayno García

ASESOR

Dr. Juan Carlos Martínez Ovando

MÉXICO, D.F.

2018

”Con fundamento en los artículos 21 y 27 de la Ley Federal de Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada **“Clasificación no supervisada utilizando un modelo bayesiano de mezclas”**, otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la biblioteca Raúl Baillères Jr., autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una prestación”

Montserrat Vizcayno García

Fecha

Firma

Índice general

1. Introducción	1
1.1. Problema de agrupamiento o segmentación	1
1.2. Segmentación basada en distancias	2
1.3. Segmentación basada en probabilidad	3
1.4. Objetivo de la tesina	4
1.5. Estructura de la Tesina	5
2. Inferencia Bayesiana	6
2.1. Consideraciones de aleatoriedad	6
2.2. Intercambiabilidad	8
2.3. Verosimilitud	9

ÍNDICE GENERAL

2.4. Teorema de Bayes	10
2.5. Teorema de Representación	11
2.6. Distribución inicial o previa	13
2.7. Distribución final o posterior	14
2.8. Distribución predictiva	15
2.8.1. Métodos de Aproximación	17
3. Clasificación basada en mezclas de distribuciones	21
3.1. Antecedentes	21
3.2. Modelos de mezclas	24
3.3. Mezcla de normales	28
3.4. <i>Label Switching Problem</i>	32
4. Clasificación con datos discretos y continuos	34
4.1. Inferencia bayesiana en modelos de mezclas	34
4.2. Revisión de la propuesta	39
4.3. Parámetros y distribución inicial	41
4.4. Especificación del kernel	43

ÍNDICE GENERAL

4.4.1. Parte discreta	43
4.4.2. Parte continua	45
4.5. Distribución final completa	46
4.6. Gibbs Sampler	47
5. Aplicación práctica	50
5.1. Objetivo	50
5.2. Descripción de la información	51
5.2.1. Descripción de la base	53
5.2.2. Análisis Exploratorio	56
5.3. Resultados de la aplicación	64
6. Conclusiones	69
6.1. Observaciones del modelo	69
Referencias	71

Índice de figuras

1.1. Segmentación basada en distancias	3
1.2. Segmentación basada en probabilidad	4
3.1. Modelo de mezcla de normales con dos componentes	31
5.1. Gráfica de correlaciones	58
5.2. Dispersión de las variables Ing tot, Monto prom y Saldo	61
5.3. Distribución de las edades de los clientes por sucursal	62
5.4. Gráfica de dispersión crédito en pagos fijos vs créditos perdidos	63
5.5. Gráfica de dispersión de Ingreso Total vs Saldo	63
5.6. Gráfica de dispersión de Monto Promedio vs Ingreso Total . .	64

ÍNDICE DE FIGURAS

5.7. Primer resultado bajo 100 observaciones con dos componentes de Saldo	65
5.8. Primer resultado bajo 100 observaciones con dos componentes de Monto promedio	66
5.9. Primer resultado bajo 100 observaciones con dos componentes de Ingreso total	67

Índice de tablas

5.1. Tabla de Media y Varianza	59
5.2. Estadísticos descriptivos	60

Capítulo 1

Introducción

1.1. Problema de agrupamiento o segmentación

La segmentación de un conjunto de datos consiste en realizar una clasificación de estos, con base en características proporcionadas por la información. Cuando los grupos sobre los cuales se realizará dicha segmentación son desconocidos, se conoce como clasificación no supervisada. El problema en el que se enfoca la clasificación no supervisada es resuelto mediante dos enfoques; el primero y más conocido es mediante argumentos geométricos o distancias,

CAPÍTULO 1: INTRODUCCIÓN

mientras que la segunda, en la que se basa este caso, utiliza distribuciones o modelos de probabilidad. El objetivo de ambos enfoques de clasificación, es lograr que los elementos asignados a un grupo esten relacionados entre sí, y sean diferentes con respecto a los objetos en los otros grupos; es decir, que sean homogéneos dentro del grupo y heterogéneos entre sí.

1.2. Segmentación basada en distancias

En el enfoque de clasificación mediante distancias, es importante destacar, que la asignación a un grupo en específico se debe a que tan cercana, en términos de distancia, está una observación del centroide; es decir, la observación se clasifica en el grupo que posee la menor distancia entre el centroide y la observación. A continuación se muestra de manera gráfica, como se miden las distancias para asignar una observación un grupo (C_1, C_2)

CAPÍTULO 1: INTRODUCCIÓN





Figura 1.1: Segmentación basada en distancias

En la figura 1.1, se asigna la observación x al grupo C_2 ya que éste es el que posee la distancia mínima entre el centroide \bar{y}_2 y la observación x .

1.3. Segmentación basada en probabilidad

En este caso, el trabajo se basa en el segundo método, el cual utiliza modelos de probabilidad para asignar las observaciones en los distintos grupos. Como se observa en la figura 1.2, un objeto se asigna al grupo con la mayor probabilidad de pertenencia $p(x_i \in C_j)$ con $j = 1, 2$.



Text

Figura 1.2: Segmentación basada en probabilidad

1.4. Objetivo de la tesina

Desarrollar un algoritmo para realizar una aplicación práctica de la clasificación no supervisada, que muestre como se clasifica la información de los clientes de una casa de empeño en k grupos, utilizando el método Gibbs Sampler, que además, mediante iteraciones, estime las distribuciones predictivas que determinan las probabilidades de pertenencia de un individuo a un grupo, y así poder clasificarlo.

1.5. Estructura de la Tesina

La estructura de este trabajo de tesina está compuesta de seis capítulos. El primer capítulo da una breve introducción a los modelos de clasificación no supervisada y sus distintos enfoques. Más adelante en el segundo capítulo, se exponen las bases y los principios del paradigma bayesiano de inferencia. En el tercer capítulo, describe el modelo de clasificación empleando una mezcla de modelos para datos mixtos (discretos y continuos). Una vez expuesta la metodología, en el capítulo cuatro se procede a desarrollar un algoritmo para enfrentar al modelo con un conjunto de datos. El quinto capítulo presenta los resultados de la aplicación práctica sobre una base de datos de una empresa de empeño, cuyo objetivo es segmentar los clientes en distintos grupos con base en la información proporcionada por cinco variables previamente seleccionadas en un análisis exploratorio. Por último en el sexto capítulo, se describen las conclusiones acerca del ejercicio práctico y los resultados del modelo. En este capítulo se discute la viabilidad de utilizar un modelo de clasificación no supervisada de esta índole.

Capítulo 2

Inferencia Bayesiana

2.1. Consideraciones de aleatoriedad

En inferencia estadística, hay dos enfoques ampliamente empleados en la práctica: la Inferencia Bayesiana y la Inferencia Frecuentista. La segunda, define la probabilidad como el límite de la frecuencia relativa de un evento en un gran número de intentos, bajo el contexto donde dichos experimentos son aleatorios y están perfectamente definidos. Por otro lado, la Inferencia Bayesiana, es capaz de asignar probabilidades a cualquier evento, aún cuando no hay un proceso aleatorio de por medio; se puede decir que, la probabilidad

CAPÍTULO 2: INFERENCIA BAYESIANA

se ve como una manera de representar el nivel de creencia sobre un evento, en ocasiones, dada una evidencia. Esto se debe a que muchas veces como es el caso de este trabajo, los datos pueden no ser aleatorios en sí mismos; sin embargo, nuestro desconocimiento de estos, antes de que sean observados nos puede conducir a consideraciones aleatorias.

La manera de cuantificar este desconocimiento es mediante una medida de probabilidad $P(x|\theta)$. Por lo que la manera en la cual se genera un aprendizaje de esta medida de probabilidad $P(x|\theta)$ para θ , es a partir de los datos, asociando variables aleatorias $X_1, \dots, X_n \sim P(x|\theta)$ con los datos x_1, \dots, x_n ; es decir, se supone que $X_1 = x_1, \dots, X_n = x_n$.

La Inferencia bayesiana involucra un proceso de aprendizaje, que consiste en modificar las creencias iniciales de los parámetros que fueron definidos antes de observados los datos, por un conocimiento posterior actualizado, que combine tanto el conocimiento previo como la información disponible (Hall, 2012). En otras palabras, un parámetro de valor desconocido θ se representa mediante la asignación de una medida de probabilidad $\pi(\theta)$ que se define con base en el nivel de información que se conoce de este parámetro.

En las siguientes secciones se hablará sobre los conceptos básicos para poder

llevar a cabo el proceso de inferencia estadística bajo el enfoque bayesiano.

2.2. Intercambiabilidad

Al relajar el supuesto de independencia, se introduce el concepto de **intercambiabilidad**, el cual reconoce que el orden de las observaciones es invariante ante permutaciones de sus índices; es decir, toda la información relevante está contenida en los valores de las x_i 's, de forma que sus índices no proporcionan información alguna. Obsérvese que el concepto de intercambiabilidad generaliza el de independencia condicional: un conjunto de observaciones independientes idénticamente distribuidas (iid) son siempre un conjunto de observaciones intercambiables (Bernardo, 1998).

Entonces, $\{X_j\}_{j=1}^{\infty}$ son intercambiables si para todo $n < \infty$,

$$P(X_1 = x_1, \dots, X_n = x_n) = P(X_{\sigma(1)} = x_1, \dots, X_{\sigma(n)} = x_n) \quad (2.1)$$

donde $\{\sigma(1), \dots, \sigma(n)\}$ es cualquier permutación de $\{1, 2, \dots, n\}$. La intercambiabilidad implica que la probabilidad es invariante al orden de las variables aleatorias y/o de los datos.

2.3. Verosimilitud

En general, para realizar el aprendizaje acerca de un modelo $P(X = x|\theta)$ a partir de un conjunto de datos observados, x_1, \dots, x_n , con $x_j \in \mathbb{R}^p$, se supone un modelo estocástico n -dimensional, tomando como supuesto adicional, que son independientes e idénticamente distribuidos, $(x_j, j = 1, \dots, n)$.

Se define un modelo paramétrico $P(X = x) = F(x|\theta)$, en el cual $F(x|\theta)$ es una función de distribución dada.¹ Utilizando el enfoque bayesiano, el modelo se puede ver como,

$$P(x_1, \dots, x_n) = \int \prod_{i=1}^n P(x_i|\theta) \pi(d\theta)$$

donde, θ es el parámetro que indiza dicha distribución y toma valores en el espacio parametral $\Theta \in \mathbb{R}^p$ (con $p < \infty$); es decir, que hay un número finito de parámetros². De esta manera tenemos bajo el supuesto de independencia, lo siguiente:

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{j=1}^n P_j(X_j = x_j) \quad (2.2)$$

¹ya sea por una función de masa de probabilidad en el caso discreto, o por una función de densidad en el caso continuo

²al contrario del caso no paramétrico, donde el número de parámetros es infinito ($\Theta \in \mathbb{R}^\infty$)

CAPÍTULO 2: INFERENCIA BAYESIANA

donde $X_j = (X_{j1}, \dots, X_{jp})$, es un vector p -dimensional.

Al considerar $P(X_j = x_j)$ como una función de distribución o densidad, de las observaciones dado el parámetro θ , $P(X_j = x_j) = F(X_j = x_j|\theta)$, obtenemos la siguiente función de verosimilitud:

$$L(x_1, \dots, x_n; \theta) = f(x_1, \dots, x_n|\theta) = \prod_{j=1}^n f(x_j|\theta) \quad (2.3)$$

2.4. Teorema de Bayes

El Paradigma Bayesiano se basa en un proceso de aprendizaje, en el cual los datos añaden nueva información al conocimiento previo y de esta forma, se actualizan las creencias sobre los parámetros de interés. Bajo este enfoque bayesiano, para realizar inferencias sobre cierta hipótesis, se deben especificar las creencias anteriores con base en información disponible antes de haber observado los datos y así describir el comportamiento del parámetro θ mediante una distribución inicial $\pi(\theta)$ definida como una medida de probabilidad sobre Θ . Esta información es entonces combinada con los datos para producir la distribución a posteriori o final, $\pi(\theta|x_1, \dots, x_n)$, que expresa lo que se conoce de los parámetros, una vez que se introdujeron los datos. Se utiliza el teo-

CAPÍTULO 2: INFERENCIA BAYESIANA

rema de Bayes como un mecanismo para combinar la información *a priori*, $\pi(\theta)$, con la información proporcionada por los datos, $P(x_1, \dots, x_n|\theta)$. Como se mencionó anteriormente, ésta última es la función de verosimilitud,

$$\pi(\theta|x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n|\theta) \cdot \pi(\theta)}{P(x_1, \dots, x_n)} \quad (2.4)$$

donde el denominador, $P(x_1, \dots, x_n) = \int_{\Theta} P(x_1, \dots, x_n|\theta) \cdot \pi(\theta) d\theta$, es una integral sobre todos los valores de θ del producto de la función de verosimilitud y la previa del parámetro θ y se toma como una constante de normalización para asegurar que $\pi(\theta|x_1, \dots, x_n)$ sea una función densidad propia.

Simplificando, el teorema de Bayes puede ser expresado de la siguiente manera,

$$\pi(\theta|x_1, \dots, x_n) \propto P(x_1, \dots, x_n|\theta) \cdot \pi(\theta) \quad (2.5)$$

donde \propto denota una relación de proporcionalidad, $P(x_1, \dots, x_n)^{-1}$

2.5. Teorema de Representación

Utilizando en concepto de intercambiabilidad, de Finetti (de Finetti, 1930) demuestra su famoso teorema de representación para variables dicotómicas. En este caso en particular, la intercambiabilidad identifica las observaciones

CAPÍTULO 2: INFERENCIA BAYESIANA

como una muestra aleatoria de un modelo probabilístico específico (Bernoulli) y garantiza la existencia más no unicidad de una distribución inicial sobre su parámetro. En el caso general, para variables aleatorias de cualquier rango y dimensión, la intercambiabilidad identifica las observaciones como una muestra aleatoria de algún modelo probabilístico y garantiza la existencia de una distribución inicial sobre el parámetro que lo describe (Bernardo, 1998).

Teorema de representación de Finetti. Si $\{X_j\}_{j=1}^{\infty}$ son variables aleatorias intercambiables, entonces existe un objeto estocástico θ , tal que:

$$P(X_1 = x_1, \dots, X_n = x_n) = \int_{\Theta} \prod_{j=1}^n P(X_j = x_j | \theta) \pi(\theta) d\theta, \quad (2.6)$$

donde $\theta \in \Theta$ se define como el límite (cuando $n \rightarrow \infty$) de una función de las X_j 's y $\pi(\theta)$ es la función de distribución inicial sobre Θ .

En otras palabras, si la secuencia de observaciones es intercambiable, cualquier subconjunto de éstas, es una muestra aleatoria de un modelo $P(X_j = x_j | \theta)$ y existe una distribución inicial $\pi(\theta)$ que describe la información inicial disponible del parámetro θ (Bernardo and Smith, 2001).

2.6. Distribución inicial o previa

La distribución inicial o previa, $\pi(\theta)$, se define como la medida de probabilidad sobre Θ que describe nuestra creencia acerca del parámetro θ , con base en el nivel de información disponible no necesariamente de datos. Existen distintas maneras de obtener la distribución inicial para θ , en algunas situaciones es posible basarse en información que proviene de evidencia acumulada de experimentos pasados. De igual manera, la previa puede determinarse de manera subjetiva con base en la experiencia de un experto. En el caso de no contar con información disponible, se puede recurrir a una distribución previa no informativa, la cual expresa sin distinción sobre diferentes valores específicos del parámetro (Congdon, 2007).

En la práctica, hay métodos que resultan tener una conveniencia analítica para la especificación de $\pi(d\theta)$, al ser estructuralmente semejante a $\prod_{i=1}^n p(x_i|\theta)$, vista como una función de θ . Entonces, $\pi(d\theta)$ y $p(x_1, \dots, x_n|\theta)$ definen la pareja conjugada, lo que lleva a $\pi(\theta)$ y $\pi(\theta|x_1, \dots, x_n)$ a ser estructuralmente semejantes. Por ejemplo, si la función de verosimilitud es de la familia Gaussiana, entonces al elegir una distribución Gaussiana como distribución previa del parámetro, la media en este caso, nos asegurará que la distribución fi-

nal sea una distribución Gaussiana. En general todas las distribuciones de probabilidad de la familia exponencial cuentan con distribuciones previas conjugadas (Hall, 2012).

2.7. Distribución final o posterior

La distribución posterior se obtiene aplicando el teorema de Bayes. Se combina la información inicial del parámetro $\theta = (\theta_1, \dots, \theta_q)$, mediante la distribución $\pi(\theta) = \pi(\theta_1, \dots, \theta_q)$ donde $(\theta \in \Theta \subseteq \mathbb{R}^q)$, y la distribución de las observaciones, mejor conocida como función de verosimilitud, suponiendo que las X_j 's son intercambiables y condicionalmente independientes dado θ . Por lo que la distribución final de θ es:

$$\pi(\theta_1, \dots, \theta_q | x_1, \dots, x_n) = \frac{\prod_{j=1}^n P(X_j = x_j | \theta_1, \dots, \theta_q) \cdot \pi(\theta_1, \dots, \theta_q)}{\int_{\Theta} \prod_{j=1}^n P(X_j = x_j | \tilde{\theta}_1, \dots, \tilde{\theta}_q) \cdot \pi(\tilde{\theta}_1, \dots, \tilde{\theta}_q) d\tilde{\theta}_1, \dots, \tilde{\theta}_q} \quad (2.7)$$

donde el denominador se define como la constante de normalización C , tal que $\pi(\theta_1, \dots, \theta_q | x_1, \dots, x_n)$ sea una densidad propia; es decir, $\int_{\Theta} \frac{1}{C} \cdot \prod_{j=1}^n P(X_j = x_j | \theta) \cdot \pi(\theta) d\theta = 1$. En la práctica, se conoce explícitamente sólo en términos

CAPÍTULO 2: INFERENCIA BAYESIANA

del numerador (Congdon, 2007),

$$\pi(\theta_1, \dots, \theta_q | x_1, \dots, x_n) \propto \prod_{j=1}^n P(X_j = x_j | \theta) \cdot \pi(\theta) d\theta \quad (2.8)$$

El paso siguiente sería el cálculo de la distribución final, que en el caso de ser conjugados, resulta ser de una forma paramétrica conocida, y de lo contrario se recurre a métodos de aproximación, debido a la imposibilidad de obtener la constante de normalización.

2.8. Distribución predictiva

La distribución predictiva define como será el comportamiento de una nueva observación x_{n+1} con base en los datos observados x_1, \dots, x_n .

$$\begin{aligned} P(X_{n+1} = x_{n+1} | X_1 = x_1, \dots, X_n = x_n) &= \frac{P(x_1, \dots, x_n, x_{n+1})}{P(x_1, \dots, x_n)} \\ &= \frac{\prod_{j=1}^n P(X_j = x_j) \cdot P(X_{n+1} = x_{n+1})}{\prod_{j=1}^n P(X_j = x_j)} \\ &= P(X_{n+1} = x_{n+1}) \\ &= F(x_{n+1} | \theta) \quad ? \end{aligned} \quad (2.9)$$

CAPÍTULO 2: INFERENCIA BAYESIANA

Como se observa en (2.9), existe un problema de predictibilidad, ya que la distribución de la nueva observación no estaría tomando en cuenta la información proporcionada por las observaciones anteriores. Para obtener la distribución predictiva bajo el enfoque bayesiano es necesario hacer uso de los conceptos definidos en la sección anterior.

$$\begin{aligned}
 P(X_{n+1} = x_{n+1} | x_1, \dots, x_n) &= \frac{P(X_{n+1} = x_{n+1} | x_1, \dots, x_n, x_{n+1})}{P(x_1, \dots, x_n)} \\
 &= \frac{\int_{\Theta} \prod_{j=1}^n P(X_j = x_j | \theta) \cdot P(X_{n+1} = x_{n+1} | \theta) \cdot \pi(\theta) d\theta}{\int_{\Theta} \prod_{j=1}^n P(X_j = x_j | \tilde{\theta}) \cdot \pi(\tilde{\theta}) d\tilde{\theta}} \\
 &= \int_{\Theta} P(X_{n+1} = x_{n+1} | \theta) \cdot \frac{\prod_{j=1}^n P(X_j = x_j | \theta) \cdot \pi(\theta) d\theta}{\int_{\Theta} \prod_{j=1}^n P(X_j = x_j | \tilde{\theta}) \cdot \pi(\tilde{\theta}) d\tilde{\theta}} \\
 &= \int_{\Theta} P(X_{n+1} = x_{n+1} | \theta) \cdot \pi(\theta | x_1, \dots, x_n) d\theta
 \end{aligned} \tag{2.10}$$

donde $\pi(\theta | x_1, \dots, x_n)$ es la distribución final o posterior de θ dado x_1, \dots, x_n , que se define como la creencia sobre el comportamiento de θ después de observar los datos. La ecuación 2.10 se puede representar como:

$$P(X_{n+1} = x_{n+1} | x_1, \dots, x_n) = E_{\theta | x_1, \dots, x_n} [P(X_{n+1} = x_{n+1} | \theta)] \tag{2.11}$$

De esa manera la predicción del comportamiento de los nuevos datos consi-

dera la información proporcionada por los datos observados anteriormente.

2.8.1. Métodos de Aproximación

El problema de cálculo en la inferencia Bayesiana se reduce a la resolución de integrales que no tienen una solución analítica viable, por lo que se requieren algoritmos de aproximación numérica. Existen distintos tipos de métodos de aproximación como son la aproximación de Laplace o el método Monte Carlo vía Cadenas de Markov (MCMC) (Hall, 2012).

I. Monte Carlo vía Cadenas de Markov

Para la aproximación de integrales, se utilizan en técnicas de simulación estocástica. Consiste en generar simulaciones de los datos para aproximar la integral que en su caso puede ser una función de distribución, conocido como el método Monte Carlo.

Supongamos que se tiene una integral de la forma: $\int h(\theta)\pi(\theta)d\theta$, donde $\theta \in \Theta \subset \mathbb{R}^p$ es una variable aleatoria, $\pi(\theta)$ es la densidad de θ que está condicionada a la información relevante disponible al momento del análisis, y $h(\cdot)$ es una función real conocida e integrable con respecto a π .

CAPÍTULO 2: INFERENCIA BAYESIANA

Si se es capaz de generar una muestra de simulaciones de tamaño T , $(\theta_1^{(t)}, \dots, \theta_q^{(t)})$, con $(t = 1 \dots T)$ independientes e idénticamente distribuidas (*iid*) de la distribución $\pi(\theta)$, podemos aproximar el valor de la integral.

Esto puede ser interpretado como el valor esperado de h sobre π , $E_\pi[h(\theta)] = \int h(\theta)\pi(\theta)d\theta$, que es aproximado, mediante un promedio de dichas simulaciones obtenidas, que son evaluadas en h , $\hat{E}_\pi[h(\theta)] = \frac{1}{T} \sum_{i=1}^T h(\theta^{(i)})$.

Este estimador, que se conoce como el estimador de Monte Carlo, es insesgado y converge casi seguramente con el valor de la integral de interés (Martínez Ovando, 2004).

Entonces, retomando la sección anterior, tenemos que la función de distribución predictiva (2.11) se puede ver de la siguiente manera:

$$E_{\theta|X_1, \dots, X_n}(P(X_{n+1}|\theta)) \approx \frac{1}{T} \sum_{t=1}^T P(X_{n+1}|\theta_1^{(t)}, \dots, \theta_q^{(t)}) \quad (2.12)$$

donde la aproximación de (2.12), se puede interpretar como el promedio empírico de $P(X_{n+1}|\theta)$.

Bajo el contexto bayesiano, generalmente conocemos la densidad $\pi(\cdot)$, salvo por una constante de normalización, que usualmente es difícil de calcular, lo que lleva al problema inicial de resolver una integral, por lo que se propone relajar el supuesto de *iid* de Monte Carlo. De esta forma, $\theta_1^{(t)}, \dots, \theta_q^{(t)}$ dependerá

CAPÍTULO 2: INFERENCIA BAYESIANA

de $\theta_1^{(t-1)}, \dots, \theta_q^{(t-1)}$; es decir, que el valor de $\theta_1^{(t)}, \dots, \theta_q^{(t)}$ estará influenciado por la información que proporcione $\theta_1^{(t-1)}, \dots, \theta_q^{(t-1)}$ y así sucesivamente para cada una de las T simulaciones. Esto se logra mediante una cadena de Markov, con una distribución de transición $g(\theta^{(t)}|\theta^{(t-1)}, X_1, \dots, X_n)$.

La unión del método de cadenas de Markov con el método de Monte Carlo, es a lo que se le denomina método Monte Carlo vía Cadenas de Markov (MCMC).

La cadena de Markov es un proceso estocástico $\{\theta^{(0)}, \theta^{(1)}, \theta^{(2)}, \dots\}$, en la cual el próximo estado $(t+1)$ depende solamente del estado actual (t) y no de los estados anteriores.

La idea central de este método es construir una cadena de transición definida por el *kernel* de transición que tenga a la distribución objetivo $\pi(\cdot)$, como invariante; es decir, que si $\theta^{(t)} \sim \pi$ implica que $\theta^{(t+1)} \sim \pi$. El *kernel* $K : \Theta \times B(\Theta) \rightarrow [0, 1]$, es la función de transición de los estados, que denota la probabilidad de transición, $K(\theta, \theta') = P[\theta^{(t+1)} = \theta' | \theta^{(t)} = \theta]$, $\forall (\theta, \theta') \in \Theta$ entre las iteraciones t y $t+1$ (Martínez Ovando, 2004). Asimismo, la cadena deberá cumplir con ciertas condiciones de regularidad que pueden ser revisadas a profundidad en (Congdon, 2007).

II. *Gibbs Sampler*

Un algoritmo en particular de cadenas de Markov que ha sido útil para problemas multidimensionales es *Gibbs Sampler*, que está definido en términos de subvectores del vector paramétrico θ .

Este método implica hacer una actualización parámetro a parámetro de cada uno de los componentes $\theta_1^{(t)}, \dots, \theta_q^{(t)}$, mediante un muestreo sucesivo de las distribuciones condicionales, que al completarse nos da la transición de $\theta^{(t-1)}$ a $\theta^{(t)}$ (Gelman and Stern, 2014).

Este algoritmo genera una secuencia de números autocorrelacionados que cumplen con las condiciones de regularidad, que eventualmente olvida los valores iniciales, $\theta_1^{(0)}, \dots, \theta_q^{(0)}$, usados para la cadena y que terminan por converger en una distribución estacionaria. De manera que, $\{(\theta_1^{(t)}, \dots, \theta_q^{(t)})\}_{t=1}^t$ se define como una cadena de Markov (Congdon, 2007).

Capítulo 3

Clasificación basada en mezclas de distribuciones

3.1. Antecedentes

Para efectos de este análisis se utilizará la clasificación no supervisada, debido a que la información no tiene clases previas en las cuales se puedan ubicar las observaciones.

El problema de la clasificación no supervisada consiste en 'adivinar' o encontrar una agrupación subyacente a los datos en J patrones distintivos, siendo

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

J típicamente desconocido, en los cuales se pueden clasificar las observaciones. Con base en los grupos definidos, se crean reglas de asociación con las cuales x_i es asignado a una clase $C_j \in \{1, 2, \dots, J\}$

Dichas reglas de asignación pueden definirse bajo dos enfoques, por medio de distancias y el otro por probabilidad.

En la escuela tradicional, la asignación de las observaciones x_i a una clase C_j se define con base en distancias.

$$x_i \in C_{j^*} \text{ si y sólo si } j^* = \operatorname{argmin}_j d(x_i, C_j).$$

Por ejemplo, para clasificar un conjunto de datos x_1, \dots, x_n se encuentran dos grupos ($J=2$) y se define la regla de asignación como el mínimo de la distancia que hay del punto x_i al centro del grupo uno (C_1) y la distancia que hay del punto x_i al centro del grupo dos (C_2).

$$x_i \in C_1 \text{ si y sólo si } \{d(x_i, C_1) < d(x_i, C_2)\}$$

donde C_1 y C_2 son los centroides de cada grupo.

Este enfoque funciona siempre y cuando los datos sean escalares, pero en caso de que sean de tipo categórico surge un problema, ya que no hay manera de medir las distancias.

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

Por otro lado, ha surgido una nueva escuela en la que las reglas de asignación se hacen con base en la probabilidad de que x_i pertenezca a C_j ; por lo que los atributos pueden ser escalares, categóricos o texto. $x_i \in C_{j^*}$ si y sólo si $j^* = \operatorname{argmax}_{j \in J} P(x_i \in C_j)$

Para comenzar la clasificación, se suponen J grupos preexistentes en los cuales al menos una observación x_i se encuentra en cada uno de estos grupos C_1, \dots, C_J . Cabe destacar que cada una de las observaciones x_i 's sólo pueden pertenecer a un sólo grupo a la vez.

$$C_j = \{x_i : x_i \sim F(x_i|\theta_j)\}$$

donde $\theta_j = T_{F_j}(x)$, definiendo a $T_{F_j}(x)$ como un atributo, por mencionar algunos ejemplos, la media, la varianza, la mediana, etc. Definimos e_j como el número de observaciones dentro del grupo C_j y se tiene que $P(x_i \in C_j) \approx \frac{e_j}{n}$. Bajo este enfoque, surgen varias problemáticas a resolver, que deben ser consideradas al momento de escoger el modelo de clasificación.

Primero, al ser un problema de clasificación no supervisada, se desconoce el número J de grupos o clases en los que se clasificaran los datos, así que se desconocen cuáles son las x_j 's pertenecen a la clase C_j . Los parámetros $\theta_1, \dots, \theta_J$ asociados con $F_1(x_1|\theta_1), \dots, F_J(x_J|\theta_J)$, son desconocidos, por lo que

será necesario estimarlos.

En la próxima sección se propone un modelo, bajo el cual se abordan estas problemáticas.

3.2. Modelos de mezclas

El método de clasificación bajo modelos de mezclas, surge como consecuencia de la búsqueda de densidades flexibles, que permitan modelar datos de distintos tipos (continuos, categóricos, ordinales, etc.), de la forma,

$$f(x) = \sum_{j=1}^J p_j f(x|\theta_j)$$

De manera incidental, al estimar $(p_i, \theta_j)_{i=1}^J$ se calcula $p(x_i \in C_j) = p_j$, lo que permite utilizar este tipo de modelos en procedimientos de segmentación.

Por consiguiente, la estructura de los modelos de mezclas es utilizada en problemas de clasificación no supervisada, asumiendo que cada una de las x_i 's puede tener una distribución f_j con probabilidad p_j .

Dependiendo del escenario que se plantee, la meta puede ser reconstruir los grupos a los que pertenecen las observaciones para proveer de estimadores para los parámetros de los diferentes grupos, o incluso, estimar el número de

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

grupos.

Las distribuciones mixtas pueden contener un modelo finito o infinito de componentes, que posiblemente pueden ser de distintos tipos de distribuciones, y describen distintas características de los datos.

En este caso, nos enfocaremos al modelo de mezclas con un número finito de componentes, que se define así,

$$P(X = x) = \sum_{j=1}^J p_j f_j(x|\theta_j) \quad (3.1)$$

donde p_j es la probabilidad de pertenecer al componente o clase C_j , y

$$\sum_{j=1}^J p_j = 1$$

Sin embargo, la manera en como esta representado el modelo en 3.1 vuelve complicado derivar el estimador de máxima verosimilitud (cuando existe) y los estimadores bayesianos.

Por ejemplo, si se considera el caso de n observaciones *iid*, $x = (x_1, \dots, x_n)$ y definimos $p = (p_1, \dots, p_J)$ y $\theta = (\theta_1, \dots, \theta_J)$, vemos que aunque se hayan utilizado previas conjugadas para cada parámetro, para obtener la distribución previa de manera explícita, requiere que se realice la expansión de la verosimilitud en k^n términos, que para la práctica resulta ser muy costoso computacionalmente hablando (Jean-Michel Marin, 2005).

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

I. Variables Latentes

Una manera de facilitar la estimación es introducir en el modelo, variables aleatorias no observadas (variables latentes) $\underline{z} = (z_1, \dots, z_n)$, que identifican a que componente j , ($j = 1, \dots, J$) pertenece cada una de las observaciones $x = (x_1, \dots, x_n)$.

$$(X_i = x_i | Z_i = z) \sim f(x | \theta_z) \quad (3.2)$$

Donde $Z_i \sim M_j(1; p_1, \dots, p_J)$. Si tomamos la ecuación 3.1 y definimos a $\pi(\theta, p)$ como la distribución inicial de (θ, p) . La distribución posterior es la siguiente,

$$\pi(\theta, p | X = x) \propto \left(\prod_{i=1}^n \sum_{j=1}^J p_j f_j(X_i = x_i | \theta_j) \right) \pi(\theta, p) \quad (3.3)$$

Definimos Z como el conjunto de todos los J_n vectores de asignación z , que podemos descomponer en una partición de J conjuntos. Para un vector de asignación dado (n_1, \dots, n_J) donde $n_1 + \dots + n_J = n$ definimos el conjunto,

$$Z_i = \left\{ \underline{z} : \sum_{i=1}^n \mathbb{1}_{z_i=1} = n_1, \dots, \sum_{i=1}^n \mathbb{1}_{z_i=J} = n_J \right\}$$

que consiste en todas las asignaciones dadas por una partición, que en este caso es determinada por el vector de asignación (n_1, \dots, n_J) . Existe un número

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

r de soluciones enteras no negativas de las n observaciones en las J clases, en las que se cumple que $\sum_{j=1}^J n_j = n$.

$$r = \binom{n+k-1}{n} \quad (3.4)$$

De esa manera tenemos la partición $Z = \cup_{i=1}^r Z_i$. Y aunque el número total de elementos de Z no sea manejable en términos computacionales J^n , el número de conjuntos de particiones es mucho más manejable al ser del orden $\frac{n^{k-1}}{(k-1)!}$.

Ahora, la distribución posterior se puede descomponer de esta manera,

$$\pi(\theta, p|x) = \sum_{i=1}^r \sum_{\underline{z} \in Z_i} p(\underline{z}) \pi(\theta, p|x, \underline{z}) \quad (3.5)$$

donde $p(\underline{z})$ se define como la probabilidad posterior, dada la asignación \underline{z} . Esta descomposición hace que la distribución posterior le asigne una probabilidad posterior $p(\underline{z})$ a cada posible asignación \underline{z} de los datos, para luego construir la distribución posterior de los parámetros, condicional a esa asignación (Jean-Michel Marin, 2005).

Entonces retomando lo anterior $p(z_j = k) = p(x_j \in C_k) = p_k$ para $k = 1, \dots, J$, se define la verosimilitud extendida como,

$$L(p_j, \theta_j)_{j=1}^J, (z_i)_{i=1}^n | x_1, \dots, x_n = \prod_{i=1}^n p_j f(x_i | \theta_k) \mathbb{1}_{(x_i \in C_k)} \quad (3.6)$$

en k^n términos, que para la práctica resulta ser muy costoso computacionalmente hablando (George, 1989).

3.3. Mezcla de normales

Para ejemplificar la complejidad de la estimación del modelo basado en mezclas de distribuciones, consideraremos el caso simple de una mezcla de normales con dos componentes. El modelo se define de la siguiente manera,

$$\pi(j, \theta_j | x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n | \theta_j, j) \cdot \pi(\theta_j | j) \cdot \pi(j)}{\sum_{j=1}^2 \{ \int_{\Theta_j} P(x_1, \dots, x_n | \theta_j, j) \cdot \pi(\theta_j | j) d\theta_j \} \pi(j)} \quad (3.7)$$

Bajo el enfoque bayesiano la ecuación (3.7) se puede representar como,

$$\pi(j, \theta_j | x_1, \dots, x_n) \propto P(x_1, \dots, x_n | \theta_j, j) \cdot \pi(\theta_j | j) \cdot \pi(j)$$

donde el denominador de (3.7) es la constante de normalización, y como se ha mencionado, su obtención es muy compleja, por lo que en esta tesis se propone una alternativa a este método.

Definimos a la distribución posterior del parámetro θ y a la función de distribución final del modelo respectivamente,

$$\pi(\theta_j | x_1, \dots, x_n, j) = \frac{P(x_1, \dots, x_n | \theta_j, j) \cdot \pi(\theta_j, j)}{\int_{\Theta_j} P(x_1, \dots, x_n | \theta_j, j) \cdot \pi(\theta_j | j) d\theta_j} \quad (3.8)$$

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

$$\pi(j|x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n|j) \cdot \pi(j)}{\sum_{j=1}^J P(x_1, \dots, x_n|j) \cdot \pi(j)} \quad (3.9)$$

donde $P(x_1, \dots, x_n|j) = \int_{\Theta_j} P(x_1, \dots, x_n|\theta_j, j) \cdot \pi(\theta_j|j) d\theta_j$, y se tienen las siguientes funciones de verosimilitud y de distribución inicial de los parámetros,

$$P(x_1, \dots, x_n|\theta_j, j) = \prod_{i=1}^n N(x_i|\theta_j, 1) \quad (3.10)$$

$$\pi(\theta_j|j) = N(\theta_j|\mu_0, \sigma_0^2 = 1) \quad (3.11)$$

Para obtener la distribución posterior de los parámetros, sustituimos en (3.8) tanto la función de verosimilitud como la distribución inicial de los parámetros.

$$\begin{aligned} \pi(\theta_j|x_1, \dots, x_n, j) &= \frac{\prod_{i=1}^n N(x_i|\theta_j, 1) \cdot N(\theta_j|\mu_0, \sigma_0^2 = 1)}{\int_{\Theta_j} \prod_{i=1}^n N(x_i|\theta_j, 1) \cdot N(\theta_j|\mu_0, \sigma_0^2 = 1) d\theta_j} \\ &\propto \prod_{i=1}^n N(x_i|\theta_j, 1) \cdot N(\theta_j|\mu_0, \sigma_0^2 = 1) \end{aligned}$$

se expanden los cuadrados con el fin de factorizar con respecto a θ_j ,

$$\begin{aligned} &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}(x_i - \theta_j)^2\right\} \cdot \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}(\theta_j - \mu_0)^2\right\} \\ &= \frac{1}{2\pi} \exp \left\{ -\frac{1}{2} \left(\sum_{i=1}^n (x_i - \theta_j)^2 + (\theta_j - \mu_0)^2 \right) \right\} \\ &= \frac{1}{2\pi} \exp \left\{ -\frac{1}{2} \left(\sum_{i=1}^n x_i^2 - 2\theta_j n\bar{x} + (n+1)\theta_j^2 - 2\theta_j\mu_0 + \mu_0^2 \right) \right\} \end{aligned}$$

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

se suma y resta el término $\left(\frac{n\bar{x} + \mu_0}{n+1}\right)$ para completar el cuadrado,

$$= \frac{1}{2\pi} \exp \left\{ -\frac{1}{2} \left(\theta_j - \frac{n\bar{x} + \mu_0}{n+1} \right)^2 \right\} \cdot \exp \left\{ -\frac{1}{2} \left(-\left(\frac{n\bar{x} + \mu_0}{n+1} \right)^2 + \frac{\mu_0^2 + \sum_{i=1}^n x_i^2}{n+1} \right) \right\} \quad (3.12)$$

De esta manera se puede ver que el primer término de (3.12) es el kernel de una distribución normal con media $\frac{n\bar{x} + \mu_0}{n+1}$ y varianza 1,

$$\pi(\theta_j | x_1, \dots, x_n, j) \sim N \left(\frac{n\bar{x} + \mu_0}{n+1}, 1 \right) \quad (3.13)$$

además, la constante de normalización de $\pi(\theta_j | x_1, \dots, x_n, j)$ que garantiza que sea una función propia es,

$$\left[\frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(-\left(\frac{n\bar{x} + \mu_0}{n+1} \right)^2 + \frac{\mu_0^2 + \sum_{i=1}^n x_i^2}{n+1} \right) \right\} \right]^{-1}$$

Los resultados obtenidos en la parte de arriba, se utilizarán para estimar la función de distribución final del modelo (3.9).

$$\pi(j | x_1, \dots, x_n) = \frac{\int_{\Theta_j} \prod_{i=1}^n N(x_i | \theta_j, 1) \cdot N(\theta_j | \mu_0, \sigma_0^2 = 1) d\theta_j \cdot \pi(j)}{\sum_{j=1}^2 \int_{\Theta_j} \prod_{i=1}^n N(x_i | \theta_j, 1) \cdot N(\theta_j | \mu_0, \sigma_0^2 = 1) d\theta_j \cdot \pi(j)}$$

donde a $\int_{\Theta_j} \prod_{i=1}^n N(x_i | \theta_j, 1) \cdot N(\theta_j | \mu_0, \sigma_0^2 = 1) d\theta_j$ se le llama verosimilitud integrada y se puede sustituir de la siguiente manera,

$$\pi(j | x_1, \dots, x_n) = \frac{\frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(-\left(\frac{n\bar{x} + \mu_0}{n+1} \right)^2 + \frac{\mu_0^2 + \sum_{i=1}^n x_i^2}{n+1} \right) \right\} \cdot \pi(j)}{\sum_{j=1}^2 \int_{\Theta_j} \prod_{i=1}^n N(x_i | \theta_j, 1) \cdot N(\theta_j | \mu_0, \sigma_0^2 = 1) d\theta_j \cdot \pi(j)}$$

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

En la figura 3.1 se ejemplifica como se verían las distribuciones del modelo de mezclas de normales cuando el número de componentes es $J = 2$.




Figura 3.1: Modelo de mezcla de normales con dos componentes

El modelo asigna una regla de pertenencia a los grupos mediante una probabilidad; sin embargo, en los puntos donde las distribuciones se intersectan, no está claro a que componente pertenece una observación, ya que dichas probabilidades son similares. Tanto la acción de encontrar la distribución del modelo como la asignación de las medidas de probabilidad, pueden resultar problemático, por lo que se proponen diferentes enfoques para abordar el

problema, como la utilización de modelos iterativos, donde se recopile información y se genere una mejor asignación de las probabilidades, para resolver el primer problema, y la introducción de variables latentes que se explica en la sección anterior, para el segundo problema.

3.4. *Label Switching Problem*

El término *label switching* se utiliza para describir la invarianza de la función de verosimilitud extendida al momento de reetiquetar a los componentes del modelo de mezclas. En otras palabras, para cualquier permutación σ de $1, \dots, k$, se define la permutación correspondiente al parámetro θ como,

$$\sigma(\theta) = ((\pi_{\sigma(1)}, \dots, \pi_{\sigma(k)}), (\theta_{\sigma(1)}, \dots, \theta_{\sigma(k)}))$$

Lo que a continuación nos lleva a la raíz del problema de *label switching*, que surge durante el proceso de estimación del modelo. La función de verosimilitud es la misma para todas las permutaciones de θ . De igual manera, bajo el enfoque bayesiano, si no se cuenta con la información previa que distinga entre los componentes del modelo de mezclas, la distribución previa $\pi(\theta)$ será la misma para todas las permutaciones y por consiguiente la distribu-

CAPÍTULO 3: CLASIFICACIÓN BASADA EN MEZCLAS DE DISTRIBUCIONES

ción posterior sera simétrica. Dicha simetría puede causar problemas cuando se busca estimar algún atributo relacionado a los componentes del modelo de manera individual. Por ejemplo, gracias a esta simetría, las funciones de densidad predictivas son las mismas para cada componente, de forma que las probabilidades de clasificación no son de utilidad para la clasificación de las observaciones en grupos, ya que son las mismas para cada observación ($1/k$). De manera similar, al tener la misma distribución posterior, la media de un parámetro dentro de un componente en específico será la misma que la de media de ese parámetro en los demás componentes del modelo, por lo que en general suele ser una estimación muy pobre para esos parámetros (Stephens, Stephens).

Se han propuesto diversas alternativas para resolver el problema, como es la de imponer una restricción (*identifiability constraint*) sobre los parámetros, como por ejemplo, ordenar las medias (o las varianzas o pesos), que desde el punto de vista Bayesiano, equivale a truncar la distribución previa original. Sin embargo esto puede llevar a modificar de manera radical el modelo de la distribución previa. Una alternativa es seleccionar una de las $k!$ regiones modales de la distribución posterior y realizar el reetiquetado con base en la proximidad a esta región. (Jean-Michel Marin, 2005)

Capítulo 4

Clasificación con datos discretos y continuos

4.1. Inferencia bayesiana en modelos de mezclas

Originalmente, los modelos de mezclas fueron desarrollados para datos categóricos; sin embargo, actualmente se ha propuesto extenderlos a datos mixtos. Más adelante se demuestra como la función de verosimilitud marginal puede ser factorizada en el producto de los componentes discretos y conti-

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

nuos para poder ser tratados por separado.

La distribución de probabilidad de los datos continuos puede deducirse, si la funcion de verosimilitud cuenta con una función de distribución previa conjugada, de manera que la distribución conjunta pueda ser determinada analíticamente. (Blomstedt et al., 2015)

Tomando en cuenta todos los conceptos definidos anteriormente, suponemos un conjunto N de n observaciones $i \in N$ que se caracterizan como vectores d -dimensionales $x^{(i)} = (x_1^{(i)}, \dots, x_d^{(i)}) \in \mathbb{R}^d$. El conjunto de datos se define como $x = (x^1, \dots, x^n)^T$. Ahora, se lleva a cabo la partición N en k conjuntos no vacíos y que a su vez no se traslapen, representados por $S = \{s_1, \dots, s_k\}$ tal que, $s_c \cup_{c=1}^k = N$, $s_c \cap s_{c'} = \emptyset \forall c, c' = 1, \dots, k$ con $c \neq c'$.

Una distribución de mezclas, puede ser definida como:

$$F(x) = P(x \in D)F(x|X \in D) + P(x \in D^C)F(x|X \in D_C), \quad (4.1)$$

donde D es un conjunto de puntos discontinuos con respecto a F y finito con cardinalidad r . Aún sin conocer la forma de la distribución del componente discreto, suponemos un vector aleatorio (Y_1, \dots, Y_r) de manera que:

$$Y_l = \begin{cases} 1, & \text{si } X = d_l \\ 0, & \text{si } x \neq d_l \end{cases}$$

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

con $l = 1, \dots, r$, por lo que la distribución de probabilidad del componente discreto se define como sigue:

$$f_D(y_1, \dots, y_r | \psi_1, \dots, \psi_r) = \prod_{l=1}^r \psi_l^{y_l} \quad (4.2)$$

donde $\psi_l = P(Y_l = 1 \text{ y } \sum_{i=1}^r \psi_i = 1)$. Ahora, para el componente continuo del modelo se define una función de densidad $f_C(x|\lambda)$.

Con los datos del grupo c y características j , que suponemos observados, se definen $x_{cj} = (x^{(1)}, \dots, x^{(n_c)})^T$, tenemos la función de verosimilitud

$$L_{x_{cj}}(w, \psi_1, \dots, \psi_r, \lambda) = \prod_{i=1}^{n_c} \left[(1-w) \prod_{l=1}^r \psi_l^{y_l^{(i)}} + w f_C(x^{(i)} | \lambda) \right] \quad (4.3)$$

donde $w = P(X^{(i)} \in D^c) \forall i = 1, \dots, n_c$, y asumiendo que las observaciones son condicionalmente independientes. Al expandir la ecuación 4.3 se obtienen 2^{n_c} términos, que complican los cálculos analíticos, debido a esto, se propone introducir la siguiente variable aleatoria:

$$Y_{r+1} = \begin{cases} 1, & \text{si } X \in D^c \\ 0, & \text{si } X \in D \end{cases}$$

y definiendo,

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

$$p_l = \begin{cases} (1-w)\psi_l, & \text{si } l = 1, \dots, r \\ w, & \text{si } l = r+1 \end{cases}$$

de manera que $\sum_{l=1}^{r+1} p_l = 1$, lo que permite que la función de verosimilitud se reescriba así,

$$L_{x_{cj}}(p_1, \dots, p_{r+1}, \lambda) = \prod_{i=1}^{n_c} \left[p_1^{y_1^{(i)}} \dots p_r^{y_r^{(i)}} + p_{r+1} f_c(x^i | \lambda)^{y_{r+1}^{(i)}} \right] \quad (4.4)$$

Finalmente, al definir $Z = X | X \in D^c$ reescribimos la función de verosimilitud separando la parte continua z_{cj} y la parte discreta y_{cj} .

$$L_{x_{cj}}(p_1, \dots, p_{r+1}, \lambda) = \prod_{l=1}^{r+1} p_l^{n_{cl}} \prod_{m=1}^{n_{c,r+1}} f_c(z_{(m)} | \lambda) = L_{y_{cj}}(p_1, \dots, p_{r+1}) L_{z_{cj}}(\lambda) \quad (4.5)$$

donde $n_{cl} = \sum_{i=1}^{n_c} y_l^{(i)}$, de forma que $\sum_{l=1}^{r+1} n_{cl} = n_c$ y $z^{(m)}$ es el m -ésimo valor observado en D^c .

Con base en la función de verosimilitud obtenida para un grupo o *cluster* se puede obtener la función marginal de verosimilitud para una partición S dada. Se define θ_{cj} de manera conjunta como $(p_{cj,1}, \dots, p_{cj,r+1}, \lambda_{cj})$ y análogamente, θ_S se define como el conjunto de parámetros de la partición S .

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

Suponiendo independencia de los clusters dados los parámetros, la función de verosimilitud conjunta para θ_S

$$L_x(\theta_S) = \prod_{c=1}^k \prod_{j=1}^d L_{y_{cj}}(p_{cj,1}, \dots, p_{cj,r+1}) L_{z_{cj}}(\lambda_{cj}) \quad (4.6)$$

y si suponemos independencia entre λ_{cj} y $(p_{cj,1}, \dots, p_{cj,r+1})$, se puede factorizar la previa $\pi(\theta_{cj})$,

$$\pi(\theta_{cj}) = \pi(p_{cj,1}, \dots, p_{cj,r}) \pi(\lambda_{cj}) \quad (4.7)$$

lo que lleva a que,

$$\pi(\theta_S) = \prod_{c=1}^k \prod_{j=1}^d \pi(p_{cj,1}, \dots, p_{cj,r+1}) \pi(\lambda_{cj}) \quad (4.8)$$

Una vez definido esto, la función de verosimilitud marginal se puede ver así,

$$\begin{aligned} p(x|S) &= \int_{\Theta_S} L_X(\theta_S) \pi(\theta_S) d\theta_S \quad (4.9) \\ &= \int_{P_S} \left[\prod_{c=1}^k \prod_{j=1}^d L_{y_{cj}}(p_{cj,1}, \dots, p_{cj,r+1}) \pi(p_{cj,1}, \dots, p_{cj,r+1}) \right] dP_S \\ &\quad \cdot \int_{H_S} \prod_{c=1}^k \prod_{j=1}^d L_{z_{cj}}(\lambda_{cj}) \pi(\lambda_{cj}) d\lambda_S \\ &= p(y|S) p(z|S) \end{aligned}$$

lo que permite separar los componetes discretos de los continuos, y así obtener las funciones de verosimilitud para cada componente (Blomstedt et al., 2015), como se muestra en la próxima sección.

4.2. Revisión de la propuesta

En esta sección se describe el modelo propuesto para clasificar datos mixtos aplicado en una base de datos que posee, tanto información categórica como continua. Este conjunto de datos se compone de p variables de conteo y d variables continuas, con n observaciones.

El modelo $p(x) = p(y, z) = \sum_{j=1}^J p_j P(y|\theta_j) P(z|\gamma_j)$, donde y representa las variables discretas y z las variables continuas. Las p variables continuas se distribuyen de la forma Normal-Multivariada, $y = X^c \sim N(\mu_j, \Sigma_j)$, mientras que cada una de las d variables de conteo tiene una distribución Poisson, $z = X_{l=1}^d \sim Po(\lambda_{lj})$.

Por lo que nuestro modelo de mezclas propuesto con K componentes se define de la siguiente manera:

$$p(z, y) = \sum_{j=1}^K \pi_j \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj}) \quad (4.10)$$

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

donde $\pi_j = p((y, z) \in C_j)$.

Ahora, como se menciona el capítulo anterior, para facilitar el cálculo de las distribuciones, se incluye la variable latente z_j al modelo, la cual actúa como variable de asignación. Debido a que x_i sólo puede pertenecer a un componente, se define a z_{ij} como la esperanza condicional a los datos observados,

$$E[z_{ij}|x] = \frac{\pi_j^{(t)} |x \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj})}{\sum_{j=1}^K \pi_j^{(t)} |x \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj})} \quad (4.11)$$

Para obtener la función de distribución conjunta, tenemos que $P(x, z; \theta) = P(z, \theta) \cdot P(x|z, \theta)$ con $\theta = (\pi, \mu, \Sigma, \lambda)$, entonces,

$$P(z, \theta) = \prod_{j=1}^K \pi_j^{z_j} \quad (4.12)$$

$$P(x|z, \theta) = (N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj}))^{z_j} \quad (4.13)$$

Por definición obtenemos la distribución conjunta del modelo incluyendo la variable latente,

$$P(x, z; \theta) = \prod_{j=1}^K \prod_{i=1}^n \left(\pi_j \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj}) \right)^{z_{ij}} \quad (4.14)$$

4.3. Parámetros y distribución inicial

Para las distribuciones iniciales, se elegirán distribuciones conjugadas que aseguren una distribución final con una forma paramétrica conocida.

Empezando por las variables continuas, se elegirán las previas de una Normal Multivariada para el parámetro de medias y una Wishart Inversa para el parámetro de la varianza, ya que al tener una función de verosimilitud Normal Multivariada, se produce una distribución posterior Normal Multivariada para el parámetro de medias y una distribución posterior Wishart Inversa para el parámetro de varianza. En el caso de las variables discretas, se elegirán la distribución previa como una Gamma ya que la función de verosimilitud esta compuesta de distribuciones Poisson y se produce una distribución posterior Gamma. Para el parámetro de proporción de la variable latente que tiene como previa una distribución Dirichlet, le corresponde una Dirichlet como distribución posterior. De manera que, las distribuciones previas de los parámetros y sus hiperparámetros correspondientes, se definen así,

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

- $\Sigma_j \sim W^{-1}(\Lambda_j, v_j)$ con una función de densidad,

$$P(\Sigma_j | \Lambda_j, v_j) \propto |\Sigma_j^{-1}|^{-(v_j+d+1)/2} \exp \left\{ -\frac{1}{2} \text{trace} [\Sigma_j^{-1} \Lambda_j] \right\}$$

donde Λ_j es la matriz de covarianzas de los datos observados y v_j es el número de variables continuas mas uno, $(d + 1)$

- $\mu_j | \Sigma_j \sim N(\varepsilon_j, \frac{\Sigma_j}{n_j})$ con función de densidad,

$$P(\mu_j | \varepsilon_j, \frac{\Sigma_j}{n_j}) \propto |\Sigma_j^{-1}|^{-\frac{1}{2}} \exp \left\{ -\frac{n_j}{2} \text{trace} [(\mu_j - \varepsilon_j)' \Sigma_j^{-1} (\mu_j - \varepsilon_j)] \right\}$$

donde ε_j es un vector de las medias observas de las variables continuas, y n_j para fines prácticos se tomo como el número total de observaciones n entre el número de componentes K

- $\lambda_{lj} \sim G(a_{lj}, S_{lj})$ con función de densidad,

$$P(\lambda_{lj} | a_{lj}, S_{lj}) \propto \lambda_{lj}^{a_{lj}} \exp \{ -S_{lj} \lambda_{lj} \}$$

donde S_{lj} es la varianza observada de la l-ésima variable discreta y a_{lj} el parámetro de forma.

- $\pi \sim Dir(\alpha_1 = 1/k, \dots, \alpha_k = 1/k)$ con función de densidad,

$$P(\pi | \alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^K \pi_j^{\alpha_j}$$

4.4. Especificación del kernel

Tomando en cuenta lo anterior, se tiene la siguiente función de distribución posterior, que está compuesta por la función de verosimilitud y las distribuciones previas de los parámetros.

$$P(\theta|x, z) = P(x|z, \theta) \cdot P(\pi|\alpha_1, \dots, \alpha_k) \quad (4.15)$$

$$\cdot \prod_{j=1}^K \left[P(\Sigma_j|\Lambda_j, v_j) \cdot P(\mu_j|\varepsilon_j, \frac{\Sigma_j}{n_j}) \cdot \prod_{l=1}^p P(\lambda_{lj}|a_{lj}, S_{lj}) \right]$$

Con el fin de ser más claros en el desarrollo de la distribución posterior, se separa la parte de las variables continuas y la parte discreta.

4.4.1. Parte discreta

Se tienen p variables de conteo son iid con una distribución Poisson, de las cuales se obtiene la parte discreta de la función de verosimilitud:

$$\begin{aligned}
 P(x|z, \theta) &= \prod_{i=1}^n \left(\prod_{l=1}^p Po(\lambda_{lj}) \right)^{z_{ij}} \\
 &\propto \prod_{i=1}^n \left(\prod_{l=1}^p \lambda_{lj}^{x_{li}} \exp \{-\lambda_{lj}\} \right)^{z_{ij}} \\
 &= \prod_{l=1}^p \prod_{i=1}^n \lambda_{lj}^{x_{li} \cdot z_{ij}} \exp \{-\lambda_{lj} \cdot z_{ij}\} \\
 &= \prod_{l=1}^p \lambda_{lj}^{\sum_{i=1}^n x_{li} \cdot z_{ij}} \exp \left\{ -\lambda_{lj} \sum_{i=1}^n z_{ij} \right\} \\
 &= \prod_{l=1}^p \lambda_{lj}^{\bar{z}_j \bar{x}_{lj}} \exp \{-\bar{z}_j \lambda_{lj}\}
 \end{aligned} \tag{4.16}$$

donde $\bar{z}_j = \sum_{i=1}^n z_{ij}$ y $\bar{x}_{lj} = \sum_{i=1}^n \frac{z_{ij} x_{li}}{\bar{z}_j}$

Ahora sustituimos dentro de la función posterior la función de verosimilitud (4.16) y las distribuciones previas conjugadas de los parámetros $P(\lambda_j|a_j, S_j)$, que serán definidas en la sección 4.3,

$$\begin{aligned}
 P(\theta|x, z) &= P(x|z, \theta) \cdot \prod_{l=1}^p P(\lambda_{lj}|a_{lj}, S_{lj}) \\
 &\propto \prod_{l=1}^p \lambda_{lj}^{\bar{z}_j \bar{x}_{lj}} \exp \{-\bar{z}_j \lambda_{lj}\} \cdot \lambda_{lj}^{a_{lj}} \exp \{-S_{lj} \lambda_{lj}\} \\
 &= \prod_{l=1}^p \lambda_{lj}^{\bar{z}_j \bar{x}_{lj} + a_{lj}} \cdot \exp \{-\lambda_{lj}(\bar{z}_j + S_{lj})\} \\
 &= \prod_{l=1}^p Ga(\tilde{a}_{lj}, \tilde{S}_{lj})
 \end{aligned} \tag{4.17}$$

4.4.2. Parte continua

Para la parte continua se tienen d variables que iid con una distribución normal-mutivariada, para desarrollar la parte continua de la función de verosimilitud,

$$\begin{aligned}
 P(x|z, \theta) &= \prod_{i=1}^n (N(x_i|\mu_j, \Sigma_j))^{z_{ij}} \quad (4.18) \\
 &\propto \left(|\Sigma_j^{-1}|^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - \mu_j)' \Sigma_j^{-1} (x_i - \mu_j) \right\} \right)^{z_{ij}} \\
 &= |\Sigma_j^{-1}|^{\frac{\sum_{i=1}^n z_{ij}}{2}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n z_{ij} \text{trace} [\Sigma_j^{-1} (x_i - \mu_j)(x_i - \mu_j)'] \right\} \\
 &= |\Sigma_j^{-1}|^{\frac{\sum_{i=1}^n z_{ij}}{2}} \exp \left\{ -\frac{1}{2} \text{trace} \left[\Sigma_j^{-1} \sum_{i=1}^n z_{ij} (x_i x_i' - \mu_j x_i' - x_i \mu_j' + \mu_j \mu_j') \right] \right\} \\
 &= |\Sigma_j^{-1}|^{\frac{\sum_{i=1}^n z_{ij}}{2}} \exp \left\{ -\frac{1}{2} \text{trace} \left[\Sigma_j^{-1} \sum_{i=1}^n z_{ij} (x_i x_i' - \bar{x}_j \bar{x}_j' + \bar{x}_j \bar{x}_j' - \mu_j x_i' - x_i \mu_j' + \mu_j \mu_j') \right] \right\} \\
 &\propto \exp \left\{ -\frac{1}{2} \text{trace} \left[\Sigma_j^{-1} \sum_{i=1}^n z_{ij} (x_i x_i' - \bar{x}_j \bar{x}_j' + \bar{x}_j \bar{x}_j' - \mu_j x_i' - x_i \mu_j' + \mu_j \mu_j') \right] \right\} \\
 &\propto |\Sigma_j^{-1}|^{-\frac{\bar{z}_j}{2}} \exp \left\{ -\frac{1}{2} \text{trace} \left[\Sigma_j^{-1} \left(\bar{z}_j (\bar{x}_j - \mu_j)(\bar{x}_j - \mu_j)' + \sum_{i=1}^n z_{ij} (x_i - \bar{x}_j)(x_i - \bar{x}_j)' \right) \right] \right\}
 \end{aligned}$$

Una vez obtenida la función de verosimilitud (4.16), se procede a desarrollar

la función posterior,

$$\begin{aligned}
 P(\theta|x, z) &= P(x|z, \theta) \cdot P(\Sigma_j|\Lambda_j, v_j) \cdot P(\mu_j|\varepsilon_j, \frac{\Sigma_j}{n_j}) \tag{4.19} \\
 &\propto |\Sigma_j^{-1}|^{-\frac{\bar{z}_j}{2}} \exp \left\{ -\frac{1}{2} \text{trace} \left[\Sigma_j^{-1} \left(\bar{z}_j(\bar{x}_j - \mu_j)(\bar{x}_j - \mu_j)' + \sum_{i=1}^n z_{ij}(x_i - \bar{x}_j)(x_i - \bar{x}_j)' \right) \right] \right\} \\
 &\quad \cdot |\Sigma_j^{-1}|^{-\frac{1}{2}} \exp \left\{ -\frac{n_j}{2} \text{trace} [(\mu_j - \varepsilon_j)' \Sigma_j^{-1} (\mu_j - \varepsilon_j)] \right\} \\
 &\quad \cdot |\Sigma_j^{-1}|^{-(v_j+d+1)/2} \exp \left\{ -\frac{1}{2} \text{trace} [\Sigma_j^{-1} \Lambda_j] \right\} \\
 &= |\Sigma_j^{-1}|^{-(\tilde{v}_j+d+1)/2} \exp \left\{ -\frac{1}{2} \text{trace} [\Sigma_j^{-1} \tilde{\Lambda}_j] \right\} \\
 &\quad \cdot |\Sigma_j^{-1}|^{-\frac{1}{2}} \exp \left\{ -\frac{\tilde{n}_j}{2} \text{trace} [(\mu_j - \tilde{\varepsilon}_j)' \Sigma_j^{-1} (\mu_j - \tilde{\varepsilon}_j)] \right\} \\
 &= N(\mu_j|\tilde{\varepsilon}_j, \frac{\Sigma_j}{\tilde{n}_j}) \cdot W^{-1}(\Sigma_j|\tilde{v}_j, \tilde{\Lambda}_j)
 \end{aligned}$$

El desarrollo completo se encuentra en el anexo.

4.5. Distribución final completa

Retomando de la sección 4.2, al juntar la parte discreta con la parte continua, incluyendo a la variable latente, se obtiene la siguiente función de distribución

final, compuesta por :

$$\begin{aligned}
 P(\theta|x, z) &= P(x|z, \theta) \cdot P(\pi|\alpha_1, \dots, \alpha_k) \\
 &\quad \cdot \prod_{j=1}^K \left[P(\Sigma_j|\Lambda_j, v_j) \cdot P(\mu_j|\varepsilon_j, \frac{\Sigma_j}{n_j}) \cdot \prod_{l=1}^p P(\lambda_{lj}|a_{lj}, S_{lj}) \right] \\
 &= \prod_{j=1}^k Dir(\pi_1, \pi_k|\tilde{\alpha}_1, \dots, \tilde{\alpha}_k) \cdot G(\tilde{a}_j, \tilde{S}_j) \cdot N(\tilde{\varepsilon}_j, \frac{\Sigma_j}{\tilde{n}_j}) \cdot W^{-1}(\tilde{\Lambda}_j, \tilde{v}_j)
 \end{aligned} \tag{4.20}$$

4.6. Gibbs Sampler

Se aplica el método de *Gibbs Sampler* al Modelo basado en Mezclas, mediante el siguiente algoritmo, que toma como referencia el Algoritmo 6 propuesto por (Liang, 2009) alicando los siguientes pasos.

1. Obtener los valores iniciales $\{\theta_j^{(0)} = (\pi_j^{(0)}, \mu_j^{(0)}, \Sigma_j^{(0)}, \lambda_j^{(0)})\}_{j=1}^K$ de los parámetros con base en las distribuciones previas definidas en la sección anterior.

- $\Sigma_j^{(0)} \sim W^{-1}(\Lambda_j, v_j)$.
- $\mu_j^{(0)}|\Sigma_j^{(0)} \sim N(\varepsilon_j, \frac{\Sigma_j}{n_j})$.
- $\lambda_{lj}^{(0)} \sim G(a_{lj}, S_{lj})$
- $\pi^{(0)} \sim Dir(\alpha_1 = 1/k, \dots, \alpha_k = 1/k)$

2. Repetir para $t = 1, 2, \dots, T$, siendo T el número de iteraciones.

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

- a) Generar las simulaciones de la variable latente $z_{ij}^{(t)} \in \{0, 1\}$ para las n observaciones, con $i = 1, \dots, n$ y

$$z_{ij}^{(t)} \sim M_k(1; p_1, \dots, p_k)$$

$$\text{donde } p_j = \left(\frac{\pi_j^{(t-1)} \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj})}{\sum_{j=1}^K \pi_j^{(t-1)} \cdot N(\mu_j, \Sigma_j) \cdot \prod_{l=1}^p Po(\lambda_{lj})} \right)$$

- b) Generar las simulaciones de las distribuciones posteriores de los parámetros para cada componente j , con $j = 1, \dots, K$.

- $\Sigma_j^{(t+1)} \sim W^{-1}(\tilde{\Lambda}_j, \tilde{v}_j)$, se definen $\tilde{\Lambda}_j$ y \tilde{v}_j como,

$$\tilde{\Lambda}_j = \Lambda_j + \sum_{i=1}^n z_{ij}(x_i - \bar{x}_j)(x_i - \bar{x}_j)' + \frac{n_j \bar{z}_j}{n_j + \bar{z}_j}(\bar{x}_j - \varepsilon_j)(\bar{x}_j - \varepsilon_j)'$$

$$\tilde{v}_j = v_j + \bar{z}_j$$

$$\text{donde } \bar{z}_j = \sum_{i=1}^n z_{ij} \text{ y } \bar{x}_j = \sum_{i=1}^n \frac{z_{ij} x_i}{\bar{z}_j}$$

- $\mu_j^{(t+1)} \sim N(\tilde{\varepsilon}_j, \frac{\Sigma_j}{\tilde{n}_j})$ donde,

$$\tilde{\varepsilon}_j = \frac{\bar{z}_j \bar{x}_j + n_j \varepsilon_j}{\bar{z}_j + n_j}$$

$$\tilde{n}_j = \bar{z}_j + n_j$$

- $\lambda_{lj}^{(t+1)} \sim G(\tilde{a}_{lj}, \tilde{S}_{lj})$, se definen \tilde{a}_{lj} y \tilde{S}_{lj} como,

$$\tilde{a}_{lj} = \bar{z}_j \bar{x}_{lj} + a_{lj}$$

$$\tilde{S}_{lj} = \bar{z}_j + S_{lj}$$

CAPÍTULO 4: CLASIFICACIÓN CON DATOS DISCRETOS Y CONTINUOS

$$\text{donde } \bar{x}_{lj} = \sum_{i=1}^n \frac{z_{ij}x_{li}}{\bar{z}_j}$$

$$\blacksquare \pi_j^{(t+1)} \sim \text{Dir}(\tilde{\alpha}_1, \dots, \tilde{\alpha}_k) \text{ donde } \tilde{\alpha}_j = \bar{z}_j + \alpha_j$$

3. Repetir el paso 2 hasta que la distribución conjunta de $(z^{(t)}, \theta^{(t)})$ no cambie.

Capítulo 5

Aplicación práctica

5.1. Objetivo

Obtener una clasificación de los clientes de la empresa de empeño en cuestión con base en los modelos descritos en los capítulos anteriores, utilizando la información contenida en las variables de la base de datos, de modo que a estos clientes se les asigne un grupo y así, con base en esta clasificación, ofrecerles distintos productos.

5.2. Descripción de la información

Los datos que se utilizaron como fuente de información, provienen de una empresa de empeño y microcréditos que comenzó en febrero del 2006, con diez sucursales en el Estado de México y Querétaro.

Primero comenzaremos explicando la forma en la se realizan los pagos del préstamo prendario. A diferencia de otras empresas del ramo, ésta ofrece tres esquemas de pago entre los cuales el cliente puede elegir, según le resulte más conveniente, para recuperar los objetos que ha empeñado:

1. **Tradicional** es la clásica forma de pago en la cual se pagan interés y se cuenta con 5 refrendos, al llegar al último refrendo se tiene que pagar el monto total del préstamo.
2. **Pagos Fijos** consiste en dividir el monto de la deuda más los intereses entre el número de semanas o meses que tiene el cliente como plazo para liquidar la deuda.
3. **Flexible** es una mezcla de los dos esquemas anteriores, consiste en ir pagando intereses o capital según le convenga hasta cubrir el monto total de la deuda en un plazo acordado.

CAPÍTULO 5: APLICACIÓN PRÁCTICA

El inventario de objetos que son admitidos para realizar un empeño, es limitado y es necesario que se encuentren dentro de la siguiente clasificación, de otra forma, el objeto no será admitido:

Metales

- oro
- plata

Electrónicos

- Televisores
- Minicomponentes
- Celulares
- Dvd's
- Consolas de video juegos
- Computadoras
- Camaras digitales
- Reproductores de mp3

Otros

- Relojes

5.2.1. Descripción de la base

La base que nos compartió la compañía se conforma de la información histórica total de 29,822 clientes. Cada una de estas observaciones (clientes) cuenta con información de 11 variables categóricas y 8 de escala de razón, que se describen a continuación:

1. **Cliente.desde** (v_1) es la fecha de registro en la que el cliente se dio de alta en el sistema.
2. **Edad** (v_2) es el número de años cumplidos a la fecha en la que se realizó la extracción de la información.
3. **Sexo** (v_3) es una variable categórica binaria que se codificó con uno en caso de ser mujer y cero en caso de ser hombre.
4. **Ciudad** (v_4) es la población donde el cliente reside.
5. **Código postal** (v_5) es el código postal que pertenece al domicilio registrado como la residencia del cliente.
6. **Colonia** (v_6) es la dirección que el cliente ha indicado como su lugar de residencia; normalmente se toma de la credencial de elector.

CAPÍTULO 5: APLICACIÓN PRÁCTICA

7. **Suc** (v_7) es el número de la sucursal en la cual el cliente fue dado de alta en el sistema.
8. **Créditos** (v_8) es el número total de créditos que se le han otorgado al cliente ha la fecha corte o de extracción.
9. **Vigente** (v_9) número de créditos que se encuentran activos, es decir, que el monto no ha sido saldado y el cliente se encuentra al corriente con los pagos.
10. **Monto.prom** (v_{10}) es la cantidad promedio de dinero otorgada al cliente de los créditos que se le ha otorgado.
11. **Cred.perd** (v_{11}) es el número de créditos que el cliente ha perdido, es decir, que no ha podido pagar para recuperar su prenda, lo que trae como consecuencia que su prenda sea adjudicada, para que después, sea vendida.
12. **Int.pag** (v_{12}) es el número de créditos en los que se realizaron pagos fuera del esquema de pagos pactado. Esto puede ocurrir cuando el cliente se atrasa y realiza un pago a destiempo con tal de no perder su prenda.

CAPÍTULO 5: APLICACIÓN PRÁCTICA

13. **Metal** (v_{13}) es el número de prendas metálicas que ha empeñado en el total de las transacciones realizadas.
14. **Electrónico** (v_{14}) es el número de prendas de tipo electrónico que ha empeñado el cliente en las transacciones realizadas a la fecha de corte.
15. **Cred.trad** (v_{17}) es el número de operaciones en las que el cliente ha escogido esquema tradicional de pagos para liquidar los prestamos / empeños.
16. **Cred.PF** (v_{18}) es el número operaciones en las que el cliente ha escogido el esquema de pagos fijos.
17. **Cred.Flex** (v_{19}) es el número de operaciones en las que el cliente ha seleccionado el esquema de pagos flexible.
18. **Ing.tot** (v_{20}) es la suma de los pagos por concepto de ingresos que ha recibido la empresa por cliente.
19. **Ing.prom** (v_{21}) es el ingreso promedio que la empresa ha recibido por el total los pagos que el cliente ha realizado desde su alta hasta la fecha de corte.

5.2.2. Análisis Exploratorio

Antes de comenzar a analizar los datos contenidos en la base, se realizó una depuración de la base de datos. Los principales puntos encontrados son los siguientes:

- Errores en captura de fechas de nacimiento. En la base original, se encontraron 119 clientes con errores en las fechas de nacimiento, debido a errores en la captura de éstas desde que fueron dados de alta en el sistema.
- Información faltante. Se encontraron 761 individuos que presentan datos faltantes en variables como código postal, municipio, sucursal, monto promedio e ingreso promedio.

Al total de 880 registros mencionados anteriormente, se decidió eliminarlos de la base para no generar un sesgo al momento del análisis de los datos.

Como resultado, la base con la cual se llevó a cabo el análisis exploratorio, que se presenta a continuación, está compuesta de 32551 observaciones y 18 variables.

Primero se realizó un análisis de correlaciones en el que se observó que las

CAPÍTULO 5: APLICACIÓN PRÁCTICA

variables más significativas son: Saldo contra Ingreso Total con 0.9, Créditos contra Creditos a Pagos Fijos con 0.8 y Creditos contra Electrónicos con .7, como se pueden observar en la gráfica 5.1.

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.1: Gráfica de correlaciones

CAPÍTULO 5: APLICACIÓN PRÁCTICA

Con base en la gráfica anterior, se ha decidido enfocarse en sólo seis variables, 3 variables continuas que son **Saldo**, **Monto.prom** y **Ing.tot**, y en tres variables de conteo **Electrónico**, **Cred.perd** y **Cred.PF**. De esta manera podremos utilizar estas variables para los componentes continuos y discretos del modelo que se definió en el capítulo anterior.

A continuación, con el fin de realizar un análisis de las variables seleccionadas, se muestran las tablas con los estadísticos descriptivos.

Tabla 5.1: Tabla de Media y Varianza

variable	media	varianza
Cred_perd	0.67	1.36
Cred_PF	1.56	9.04
Electronico	16.23	1565.86
Ing_tot	5175.00	4990698327.63
Monto_prom	1296.89	7208400.90
Saldo	640.16	236844874.62

CAPÍTULO 5: APLICACIÓN PRÁCTICA

Tabla 5.2: Estadísticos descriptivos

	Cred_perd	Cred_PF	Electronico	Ing_tot	Monto_prom	Saldo
Min. :	0	0	0	-251	0	0
1st Qu.:	0	0	1	100	500	0
Median :	0	1	7	407	800	0
Mean :	0.6707	1.56	16.23	5175	1297	640.2
3rd Qu.:	1	2	18	1631	1350	0
Max. :	59	168	3439	11024580	143881	2674250

En la figura 5.2 de abajo, se puede apreciar como están altamente correlacionadas las tres variables: Saldo, Monto.prom e Ing.tot. Esto implica que al momento de modelar las variables bajo el modelo seleccionado se podrán distribuir como:

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.2: Dispersión de las variables Ing tot, Monto prom y Saldo

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.3: Distribución de las edades de los clientes por sucursal

Ahora, en la gráfica de caja y brazos (5.3) muestra como se distribuyen a las edades según la sucursal.

En cuanto a las variables elegidas para el análisis y aplicación del modelo, a continuación se presentan los

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.4: Gráfica de dispersión crédito en pagos fijos vs créditos perdidos




Figura 5.5: Gráfica de dispersión de Ingreso Total vs Saldo




Figura 5.6: Gráfica de dispersión de Monto Promedio vs Ingreso Total

5.3. Resultados de la aplicación

Una vez realizado el análisis exploratorio de los datos, y contar con una base de datos consistente compuesta de cinco variables, Saldo, Monto.prom, Ing.tot, Cred.PF y Cred.perd, donde las primeras tres son continuas, mientras que las últimas dos son discretas.

Para un primer acercamiento y con el fin de realizar unas pruebas sobre el desempeño del modelo, se corrió el algoritmo dearrollado en R (incluido

CAPÍTULO 5: APLICACIÓN PRÁCTICA

en el Anexo 1) sobre una muestra de 100 observaciones y 30 iteraciones. A continuación se muestran las distribuciones por componente de la variables variables utilizadas.

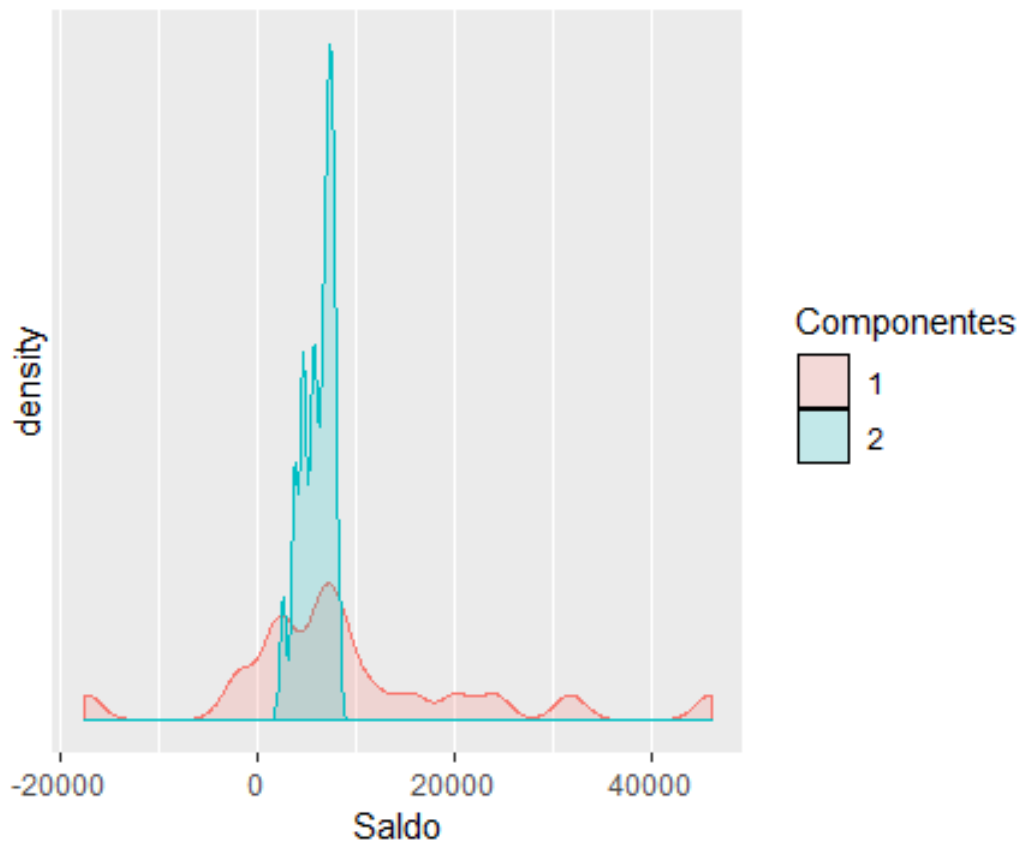


Figura 5.7: Primer resultado bajo 100 observaciones con dos componentes de Saldo

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.8: Primer resultado bajo 100 observaciones con dos componentes de Monto promedio

CAPÍTULO 5: APLICACIÓN PRÁCTICA




Figura 5.9: Primer resultado bajo 100 observaciones con dos componentes de Ingreso total

En este primer acercamiento se puede ver como no las distribuciones de ambos componentes se traslapan, por lo que no es posible hacer una distinción clara sobre la asignación probabilística de las observaciones, por lo que se decidió realizar más pruebas con muestras más grandes y mayor número de

CAPÍTULO 5: APLICACIÓN PRÁCTICA

iteraciones, para observar si con estos ajustes, el algoritmo presenta un mejor resultado para asignar a los grupos de clasificación.

Capítulo 6

Conclusiones

6.1. Observaciones del modelo

1. Parametrización de la distribución previa $Ga(\alpha, \beta)$ para las variables de conteo. se designó para el parámetro de forma α un valor arbitrario $a_{lj} \in N$, mientras que para el parametro de escala β se tomó la varianza observada S_{lj} de la variable en cuestión, y una distribución posterior $Ga(\tilde{\alpha}, \tilde{\beta})$ tiene como parámetros $\tilde{\alpha} = \bar{z}_j \bar{x}_j + a_{lj}$ y $\tilde{\beta} = S_{lj} + \bar{z}_j$. Por lo que en cada iteración los parámetros van creciendo muy rápidamente y pronto, los valores observados se encuentran fuera de la densidad y

CAPÍTULO 6: CONCLUSIONES

al valuarlas nos da cero. Aún cambiando el parámetro de escala a un valor arbitrario pequeño para la previa, sigue creciendo muy rápido.

Bibliografía

Bernardo, J.-M. (1998). Bruno de Finetti en la estadística contemporánea.

Historia de la Matemática en el Siglo XX, S. Rios (ed.), Real Academia de Ciencias, Madrid, 63 – 80.

Bernardo, J. M. and A. F. Smith (2001). Bayesian theory.

Blomstedt, P., J. Tang, J. Xiong, C. Granlund, and J. Corander (2015).

A Bayesian Predictive Model for Clustering Data of Mixed Discrete and Continuous Type. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 37(3), 489–498. VK: Kaski, S.; COIN; HIIT.

Congdon, P. (2007). *Bayesian Statistical Modelling*, Volume 704. John Wiley & Sons.

de Finetti, B. (1930). *de Finetti*.

BIBLIOGRAFÍA

- Gelman, Andrew y Carlin, J. B. and D. B. Stern, Hal S y Rubin (2014). *Bayesian Data Analysis*, Volume 2. Chapman y Hall/CRC Boca Raton, FL, USA.
- George, B. (1989). *Verosimilitud Extendida*.
- Hall, B. (2012). Bayesian inference. *Statisticat, LLC*.
- Jean-Michel Marin, Kerrie Mengersen, C. P. R. (2005). Bayesian modelling and inference on mixtures of distributions. In D. Dey and C. Rao (Eds.), *Bayesian Thinking*, Volume 25 of *Handbook of Statistics*, pp. 459 – 507. Elsevier.
- Liang, L. (2009). On simulation methods for two component normal mixture models under Bayesian approach.
- Martínez Ovando, J. C. (2004). Un criterio predictivo de selección de modelos para series de tiempo. Master’s thesis, IIMAS–UNAM.
- Stephens, M. Dealing with label switching in mixture models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 4, 795–809.